

Interpretacja wyników analizy wrażliwości metodą Morrisa dla Twojego modelu SD

Streszczenie wykonawcze

Przekazane wykresy (pięć histogramów/wykresów słupkowych μ) *pokazują globalną analizę wrażliwości metodą Morrisa (elementary effects) dla pięciu metryk wyjściowych Twojego modelu SD (m.in. czas do krytycznego spadku stabilności i szczyt protestów). Wartości μ i σ zostały zapisane w `morris_indices.json` [filecite\turn31file0](#), a syntetyczna interpretacja jest w `README.MD` [filecite\turn31file1](#).*

Najważniejszy wynik strukturalny jest spójny przez wiele metryk: model zachowuje się jak system zdominowany przez 3 bloki sprzężeń: - **blok informacji** (kontrola informacji $\rightarrow$ protest $\rightarrow$ stabilność), szczególnie parametr `k_info`, który zdecydowanie dominuje *czas do destabilizacji*, - **blok protestu** (`k_mob`, `k_demob`, `k_loss_p`) kontrolujący *szczyt protestów* i mocno wpływający na *czas destabilizacji*, - **blok aparatu** (`k_loss_l`, `k_split`) kontrolujący *średnią lojalność aparatu*.

Jednocześnie widoczny jest mocny sygnał potencjalnego artefaktu definicyjnego: **prawdopodobieństwo „pęknięcia elit”** jest praktycznie czułe wyłącznie na `k_elite_cost`, co może oznaczać, że ta metryka jest **zbyt binarna / progowa** albo że w modelu brakuje realnych kanałów, przez które inne parametry mogą „dowieźć” rozpad elit (lub ich zakresy nie obejmują obszaru przełączenia).

Kontekst danych i co dokładnie pokazują wykresy

Masz 5 wykresów μ^* (średnia z wartości bezwzględnych elementarnych efektów) dla metryk:

- `Tcrit_mean` — średni czas do krytycznego spadku stabilności,
- `elite_fracture_prob_mean` — średnie prawdopodobieństwo pęknięcia elit,
- `peak_protest_mean` — średni szczyt protestów,
- `end_displaced_m_mean` — średnia końcowa liczba przesiedlonych (wartość „m” sugeruje miliony, ale jednostka jest **nieokreślona**),
- `avg_loyal_mean` — średnia lojalność aparatu.

Same wartości μ , μ , σ i *przedziały ufności* μ (`mu_star_conf`) znajdują się w `morris_indices.json`. [filecite\turn31file0](#)

W interpretacji Morrisa kluczowe są trzy statystyki (wprost tak raportuje to dokumentacja SALib ¹):

- μ : średnia elementarnych efektów (kierunek wpływu),
- μ^* : średnia z wartości bezwzględnych (siła wpływu „bez względu na znak”),
- σ : odchylenie standardowe elementarnych efektów (wskaźnik nieliniowości i/lub interakcji). ²

Ujęcie „screeningowe” Morrisa (czyli: znaleźć niewielki zbiór parametrów dominujących) jest klasycznie rozwinięte i ustandaryzowane u Francesca Campolongo ³ i współautorów, łącznie z interpretacją μ i σ jako rozróżnienia: *zaniedbywalne vs liniowe i addytywne vs nieliniowe / interakcyjne*. ⁴

Interpretacja każdego wykresu μ^* i „co to mówi o Twoim modelu”

Poniżej podaję interpretację w logice: **dominujące parametry** → **mechanizm SD** → **konsekwencje interpretacyjne**. Liczby μ^* pochodzą z `morris_indices.json`. [filecite\turn31file0](#)

Czas do destabilizacji `Tcrit_mean`

Dominujące parametry wg μ^* :

parametr	μ^*	znak μ	skrót interpretacji
<code>k_info</code>	61.4	+	silna kontrola informacji wydłuża czas do kryzysu
<code>k_loss_p</code>	56.3	–	większy „koszt protestu dla stabilności” skraca czas do kryzysu
<code>k_demob</code>	25.2	+	sprawniejsze wygaszanie protestu opóźnia kryzys
<code>k_rally_s</code>	23.6	+	„rally around the flag” opóźnia kryzys
<code>k_mob</code>	4.2	–	mobilizacja protestu skraca czas do kryzysu

Wniosek strukturalny: **czas do załamania stabilności jest kontrolowany przez kanał informacja → protest → stabilność**, a nie bezpośrednio przez gospodarkę. To dokładnie pokrywa się z Twoim opisem w README: „informacja + protest + represja” oraz wskazaniem `k_info` jako najważniejszego parametru. [filecite\turn31file1](#)

Ważna uwaga diagnostyczna: dla wielu top-parametrów stosunek σ/μ jest bliski lub większy od 1 (w JSON widać duże σ dla `k_info` i `k_loss_p`), co sugeruje, że ich wpływ jest silnie zależny od kontekstu (interakcje/nieliniowości). To jest klasyczny sygnał Morrisa: wysoki μ + wysoki σ → „czynnik ważny, ale działa nieliniowo lub w interakcjach”. ⁵

Szczyt protestów `peak_protest_mean`

Dominujące parametry:

parametr	μ^*	znak μ	skrót interpretacji
<code>k_demob</code>	0.85	–	większa demobilizacja obniża maksimum protestów
<code>k_mob</code>	0.45	+	większa mobilizacja podnosi maksimum protestów
<code>k_info_emerg</code>	0.085	–	„tryb wyjątkowy info” obniża maksimum protestów

Wniosek: **protesty w Twoim modelu są klasycznym układem starcia dwóch przepływów**: mobilizacja vs demobilizacja (represja/zmęczenie/warunki). To jest spójne z Twoją notą: „mobilizacja ↔ represja” oraz „protest = f(mobilizacja, represja)”. [filecite\turn31file1](#)

Dodatkowy sygnał metodyczny: `k_info_emerg` ma relatywnie wyższe σ względem μ^* (w danych), co jest typowe dla parametru, który działa głównie w określonych reżimach (np. dopiero gdy protest przekracza próg, uruchamia się „tryb wyjątkowy”). W system dynamics to jest klasyczna „bramka nieliniowa”.

Kryzys humanitarny / przesiedlenia end_displaced_m_mean

Dominujące parametry:

parametr	μ^*	znak μ	skrót interpretacji
k_demob	3.68	–	skuteczna demobilizacja zmniejsza końcowe przesiedlenia
k_mob	1.68	+	większa mobilizacja protestu zwiększa przesiedlenia
k_info_emerg	0.23	–	silniejsza kontrola w trybie wyjątkowym zmniejsza przesiedlenia
k_san_oil	0.15	+	większa wrażliwość ropy na sankcje zwiększa przesiedlenia (kanałem ekonomicznym)
k_pi_san	0.083	+	większy pass-through sankcji do inflacji zwiększa przesiedlenia

Tutaj widać interesującą rzecz: choć w Tcrit_mean gospodarka wygląda na „pośrednią”, to w przesiedleniach pojawiają się już parametry kanału ekonomicznego (k_san_oil, k_pi_san). Interpretacja zgodna z SD: migracje/przesiedlenia często rosną przez *mieszankę* przemocy/represji i pogorszenia warunków bytowych.

Natomiast nadal dominują parametry protestu (k_demob, k_mob), co potwierdza Twoją notę: „przesiedlenia wynikają z represja + protest”.

Średnia lojalność aparatu avg_loyal_mean

Dominujące parametry:

parametr	μ^*	znak μ	skrót interpretacji
k_loss_l	0.297	–	„koszt utrzymania aparatu” eroduje lojalność
k_split	0.267	–	parametr pęknięcia aparatu eroduje lojalność
(reszta)	«	—	wpływ wtórny

Wniosek: model ma bardzo wyraźny „rdzeń autokratyczny”: **lojalność aparatu jest najbardziej czuła na koszty i spójność aparatu**, co jest spójne z Twoim opisem: „pieniądze + jedność aparatu”.
filecite turn31file1

Metodycznie warto zauważyć, że oba dominujące parametry mają σ porównywalne z μ^* (w danych), co sugeruje, że lojalność aparatu jest „wrażliwa” na punkt pracy modelu (interakcje z protestami, fiskalnością, stratami).

Pęknięcie elit elite_fracture_prob_mean

Wykres pokazuje niemal wyłącznie:

parametr	μ^*
<code>k_elite_cost</code>	0.35
pozostałe	~ 0

To jest wynik bardzo jednoznaczny i zgadza się z Twoim README.

Jednocześnie to najbardziej „podejrzany” diagnostycznie wynik: jeśli metryka jest *prawdopodobieństwem zdarzenia progowego* (0/1), metoda Morrisa często ujawnia wyłącznie te parametry, które „przesuwają” układ przez próg, podczas gdy parametry wpływające na trajektorie, ale nie „przebijające” progu w przyjętych zakresach, wydają jako ~ 0 . To nie znaczy, że nie są ważne w rzeczywistości — tylko że w Twojej implementacji i w przyjętych zakresach nie decydują o przekroczeniu warunku pęknięcia. Dokumentacja SALib explicite ostrzega, że μ (kierunek) może być mniej wiarygodne w pewnych ustawieniach (np. grupowanie), a praca Campolongo opisuje różnice między addytywnością a interakcjami — w metrykach progowych te rozróżnienia bywają „spłaszczane”. ⁶

Rekomendacja badawcza: obok `elite_fracture_prob_mean` warto liczyć również *ciągłe* metryki elit, np. `min(E)`, `mean(E)` albo `time_to_elite_fracture`, bo wtedy zobaczysz wpływy pośrednie i unikniesz „zera Morrisa” wynikającego z binarności.

Synteza międzywyjściowa: co te wykresy mówią o strukturze Twojego modelu SD

Zestawiając wszystkie wykresy, otrzymujesz bardzo spójny obraz architektury modelu:

- **Kanał informacyjny** (`k_info`, `k_info_emerg`) jest kluczowy dla *Tcrit* (czas do destabilizacji) i widoczny w protestach oraz migracjach. To oznacza, że model wytwarza silną pętlę sprzężenia: kontrola informacji → tłumienie koordynacji → spowolnienie eskalacji protestu → opóźnienie spadku stabilności. Jest to wprost opisane w Twoich notach.
- **Kanał protestu** (`k_mob`, `k_demob`, `k_loss_p`) steruje zarówno *szczytem protestów*, jak i *czasem destabilizacji*. Czyli Twoja stabilność polityczna jest w modelu „napędzana” przez dynamikę protestu. `filecite[turn31file1]`
- **Kanał aparatu** (`k_loss_l`, `k_split`) steruje lojalnością aparatu. To jest zgodne z typową hipotezą SD o autokracjach: aparat jest „buforem” stabilności, ale zależy od zasobów i spójności (w modelu: koszty + pęknięcie). `filecite[turn31file1]`

Istotny wynik uboczny: parametry stricte ekonomiczne (`pi_base`, `k_pi_war`, `k_pi_san`, `k_san_oil`, `k_war_oil`) mają w `Tcrit_mean` niskie μ . W Twoim README interpretujesz to jako „ekonomia pośrednia”. `filecite[turn31file1]` To jest wiarygodna interpretacja dla tej konkretnej specyfikacji* SD, ale warto ją traktować jako hipotezę do falsyfikacji: w alternatywnej parametryzacji (silniejsze sprzężenie inflacja → krzywda → protest, brak saturacji, dłuższe opóźnienia) ekonomia może wejść na wyższy poziom ważności.

Konsekwencje praktyczne: jak wykorzystać te wyniki w kalibracji i falsyfikacji

Ponieważ Morris jest metodą screeningową (ma wskazać „kilka ważnych gałek”), Twoje wykresy dają bardzo konkretne priorytety pracy badawczej:

Najpierw doprecyzuj i kalibruj parametry z najwyższym μ^* dla metryk strategicznych:

- dla *Tcrit* (stabilność): `k_info`, `k_loss_p`, `k_demob`, `k_rally_s`, `k_mob`
- dla szczytu protestów: `k_demob`, `k_mob`, `k_info_emerg`
- dla lojalności aparatu: `k_loss_l`, `k_split`

Następnie użyj fal 2009/2019/2022/2026 jako testów falsyfikacyjnych, ale dopasuj je do tego, co naprawdę „steruje” model:

- 2022: test pętli protest-represja-informacja (kontrola internetu, zdolność wygaszania protestu). W literaturze zdarzeniowej ACLED 2022 jest opisywany jako fala o wyjątkowej skali i trwałości, co jest dobrym „benchmarkiem” dla dynamiki `k_mob` i `k_demob`. (Jeżeli Twój model nie potrafi odtworzyć długotrwałego plateau protestów przy jednoczesnych represjach/shutdownach, to jest falsyfikacja mechanizmu). ⁷
- 2026: test „nagłego przełączenia” kontroli informacji. Komunikat ONZ odnosi się do startu protestów po szoku walutowym i odcięciu internetu w trakcie eskalacji. To nadaje się do testowania `k_info_emerg` i tego, czy blackout działa krótkoterminowo stabilizująco, ale jakim kosztem w dłuższym okresie. ⁷ (Tu w samym modelu: blackout jest parametrem, nie „instrukcją”, a falsyfikacja ma charakter naukowy.)

Wreszcie, zaplanuj analizę wariancji Sobola jako „drugi krok” po Morrisie. Morris mówi „co ważne”; Sobol mówi „ile wariancji wyjaśnia” i lepiej radzi sobie z rankingiem globalnym, zwłaszcza gdy wskaźniki mają nieliniowości i interakcje. W SALib masz obie metody, a klasyczna praca Andrea Saltelli ⁸ opisuje wariacyjne indeksy i ich interpretację. ⁹

Ograniczenia interpretacyjne i uwagi etyczno-prawne

Analiza Morrisa jest bardzo dobra do screeningu, ale ma ograniczenia:

- Jeżeli metryka jest binarna lub mocno progowa (*elite_fracture_prob_mean*), Morris łatwo pokazuje „jedną gałąź”, która przesuwą układ przez próg, a pozostałe wyglądają na zerowe — co może być artefaktem zbyt wąskich zakresów parametrów lub definicji metryki. ⁶
- Duże σ względem μ^* oznacza, że parametr działa w interakcjach — więc kalibracja „po kolei” (parametr po parametrze) może być niestabilna. Potrzebujesz kalibracji wieloparametrowej lub przynajmniej iteracyjnej (blokowej).
- Same wykresy nie mówią nic o „prawdziwości” modelu — mówią o **strukturze wrażliwości w obrębie tej specyfikacji i zakresów parametrów**.

W kontekście wrażliwego tematu (model konfliktu dotyczący Iran ¹⁰ i NATO ¹¹): ta interpretacja ma charakter metodologiczny i badawczy. Nie jest to instrukcja działań zbrojnych ani „optymalizacji ataku”, a parametry odnoszą się do abstrakcyjnych zależności systemowych i hipotez naukowych.

¹ ⁹ GitHub - SALib/SALib: Sensitivity Analysis Library in Python. Contains Sobol, Morris, FAST, and other methods.

https://github.com/SALib/SALib?utm_source=chatgpt.com

² ³ ⁶ ⁸ ¹¹ SALib.analyze.morris — SALib's documentation

https://salib.readthedocs.io/en/stable/_modules/SALib/analyze/morris.html?utm_source=chatgpt.com

⁴ ⁵ ⁷ ¹⁰ An effective screening design for sensitivity analysis of large models - ScienceDirect

https://www.sciencedirect.com/science/article/abs/pii/S1364815206002805?utm_source=chatgpt.com