

Sobol, HyperCube i Monte Carlo: metaprzestrzeń oraz sposoby mapowania metaprzestrzeni na struktury

Streszczenie wykonawcze

Badanie dotyczy tego, jak **zdefiniować metaprzestrzeń (hipersześcian parametrów) i mapować ją na struktury** (grafy, hipergrafy, kompleksy symplecjialne, sieci wielowarstwowe, graphony), a następnie jak użyć **globalnej analizy wrażliwości Sobola** do identyfikacji **metarelacji** (interakcji między wymiarami metaprzestrzeni, które modulują strukturę i/lub dynamikę na tej strukturze). Rdzeniem jest formalizm dekompozycji ANOVA/Hoeffding-Sobol na hipersześcianie oraz estymacja indeksów metodami Monte Carlo / quasi-Monte Carlo. ¹

Najpierw przeszukano (konektor GitHub, zgodnie z kolejnością) repozytoria: `DonkeyJLove/sbom`, `DonkeyJLove/writeups`, `DonkeyJLove/chunk-chunk`, `DonkeyJLove/swarm`, `DonkeyJLove/ai_platform`, `DonkeyJLove/HA2D`, `DonkeyJLove/glitchlab`. W repozytoriach **nie znaleziono gotowej, nazwanej biblioteki „Sobol/QMC/hypergraph”** jako kompletnego modułu badawczego; znaleziono natomiast **konkretne elementy infrastruktury badawczej i artefakty mapowania „proces→graf”** (pipeline jako DAG, metryki grafowe, polityki deterministyczności, SBOM jako graf zależności). Szczególnie użyteczne są: budowa liniowego DAG z metryk pipeline'u (glitchlab), obliczanie metryk grafowych (PageRank, betweenness approx, itd.), oraz opis SBOM jako „markera strukturalnego” (graf zależności + analiza delt). ^{2 3 4}

Po kwerendzie repo wykonano web research (priorytet: prace pierwotne Sobola i Saltellego, projekty ANOVA Jansen, QMC/Sobol sequences i RQMC, oraz literatura o strukturach wyższego rzędu: hipergrafy, kompleksy symplecjialne, graphony, motywy i higher-order models). ⁵

Informacje krytyczne do doprecyzowania

Aby domknąć SPEC i móc uruchomić eksperyment „metaprzestrzeń → struktura” w trybie audytowalnym, musisz doprecyzować:

- **Definicję metaprzestrzeni:** lista parametrów $X_1, \dots, X_D$, zakresy oraz czy wejścia są niezależne czy skorelowane (klasyczny Sobol/Saltelli zakłada wejścia niezależne/nie skorelowane). ⁶
- **Definicję przestrzeni struktur:** czy generujesz grafy dyadyczne, hipergrafy, kompleksy symplecjialne, sieci wielowarstwowe, graphony, czy też „higher-order models” oparte o zależności ścieżkowe. ⁷
- **Wybór mapowania:** deterministyczne $g(X)$ vs probabilistyczne $S \sim P(\cdot | X)$ (drugi przypadek wymusza politykę replikacji stochastycznej i separację seedów). ⁸
- **Zestaw metryk strukturalnych $m(S)$** (ile, jakie, statyczne vs po czasie), oraz co jest konkretną zmienną wyjściową Y do Sobola (skalar, wektor, trajektoria). ⁹
- **Budżet obliczeniowy:** koszt wygenerowania struktury i policzenia metryk $\times$ liczba ewaluacji (Saltelli/Jansen to rząd $(D + 2)N$ uruchomień dla S_1 i S_T). ¹⁰

- **Kryteria „dobrego mapowania”**: co znaczy, że mapowanie działa (stabilność rankingów S_i , zgodność z testami na benchmarkach, brak artefaktów progowania, odporność na zmianę rozkładów). ¹¹

W miejscach, gdzie parametry nie są określone, poniżej oznaczam to jako „**nieokreślone**” i podaję rozsądne warianty.

Wyniki przeszukania repozytoriów GitHub

Poniżej minimalistyczny, praktyczny zapis rezultatów kwerendy pod kątem „metaprzestrzeń → struktury” (w sensie: istniejące elementy do budowy pipeline’u, grafów, metryk i rygoru odtwarzalności):

- `DonkeyJLLove/sbom`: plik o SBOM jako *markerze strukturalnym* i „grafie zależności” (użyteczne jako przykład mapowania artefaktu na strukturę + analiza delt). ⁴
- `DonkeyJLLove/writeups`: szkic eksperymentu z Monte Carlo (seed, RNG) — nadaje się jako wzorzec „minimalnego, jawnego” MC. ¹²
- `DonkeyJLLove/chunk-chunk`: znalezione artefakty „mosaic/9d” i protokół (potencjalnie jako format protokołu eksperymentalnego/specyfikacji). ^{13 14}
- `DonkeyJLLove/swarm`: dokumenty polityk/bezpieczeństwa (jako wzorzec formalizowania reguł/polityk — analogicznie do polityk mapowania i seedów). ^{15 16}
- `DonkeyJLLove/ai_platform`: dokument „MOSAIC” i `platform.md` (jako format raportowania/porównywania i warstwa platformowa testów). ^{17 18}
- `DonkeyJLLove/HA2D`: spec HUD (dobry wzorzec formatu SPEC: kontrakt wejść/wyjść/widoków). ¹⁹
- `DonkeyJLLove/glitchlab`: kluczowe dla „mapowania na strukturę”:
- budowa liniowego DAG z kroków pipeline’u i metryk z cache (eksport JSON dla GUI/HUD), ²
- obliczanie metryk grafowych (PageRank, betweenness approx, harmonic closeness, LPA communities), ³
- dodatkowe pliki do grafu projektu i formatów eksportu (wsparcie audytu). ²⁰

Wniosek praktyczny: repozytoria dostarczają **silnej bazy „reżimu absolutnego”** (DAG, metryki, artefakty) i przykładów „struktura jako obiekt badania”, ale brak wprost gotowego modułu QMC/Sobol/hypergraph sugeruje, że część stricte matematyczna powinna być dołączona jako osobny moduł (np. Python/SALib, R/sensitivity) wraz z SPEC i testami benchmarkowymi. ²¹

Metaprzestrzeń i formalne mapowania na struktury

Definicja metaprzestrzeni i hipersześcianu

W klasycznym ujęciu Sobola metaprzestrzeń wejść jest rozważana jako **D -wymiarowy hipersześcian** (często po normalizacji do $[0, 1]^D$), a model jest funkcją na całym pudełku, nie „w punkcie”. ²²

Formalnie: - metaprzestrzeń parametrów:

$$X = (X_1, \dots, X_D) \in \mathcal{X} = \prod_{i=1}^D \mathcal{X}_i$$

- często stosuje się generator punktów $U \in [0, 1]^D$ i transformację do rozkładów wejść:

$$X_i = F_i^{-1}(U_i)$$

gdzie F_i to dystrybuanta wejścia (wówczas rozkłady są częścią definicji problemu). 6

Nieokreślone (do SPEC): lista parametrów, ich zakresy i rozkłady F_i . Minimalne, sensowne warianty: - wariant „agnostyczny”: $X_i \sim U[a_i, b_i]$ (dobry start, ale domenowo słaby), - wariant „ułamki/progi”: $X_i \sim \text{Beta}(\alpha_i, \beta_i)$ na $(0, 1)$, - wariant „skale dodatnie”: lognormal / gamma (gdy parametr jest dodatnią skalą). 6

Przestrzeń struktur i mapowanie

Definiujesz przestrzeń struktur $\mathcal{S}$ oraz mapowanie g : - deterministycznie:

$$S = g(X) \in \mathcal{S}$$

- probabilistycznie (generator struktur):

$$S \sim P(\cdot | X)$$

W konsekwencji metryki strukturalne:

$$Y = m(S) \quad (\text{skalar lub wektor metryk})$$

a dalej liczysz Sobola dla każdego wyjścia Y . 1

Typy struktur, które obejmuje to badanie (i dlatego warto je rozróżniać): - **grafy dyadyczne** (krawędzie 2-elementowe), - **hipergrafy** (hiperkrawędzie grupowe), - **kompleksy sympleksyjne** (relacje grupowe z własnością „domknięcia na ściany”), - **modele wyższego rzędu zależności ścieżkowych** (gdy istotny jest kontekst i pamięć na ścieżkach), - **graphony** jako probabilistyczna reprezentacja (szczególnie dla gęstych grafów). 7

Kluczowe merytorycznie: literatura pokazuje, że „wyższy rząd” nie jest kosmetyką; dynamika i wnioski mogą zależeć od tego, czy tę samą intuicję modelujesz jako hipergraf czy jako kompleks sympleksyjny.

23

Katalog metod mapowania metaprzestrzeni

Poniżej „biblioteka mapowań” — zorganizowana dokładnie według klas, o które prosisz. Każde mapowanie opisuję jako funkcję (lub rodzinę funkcji) g , która bierze próbkę X i zwraca strukturę.

Mapowanie bezpośrednie: próbkowanie $\rightarrow$ atrybuty węzłów/krawędzi

Wariant: topologia stała (np. ten sam graf bazowy), a X ustawia: - wagi krawędzi (weights), - prawdopodobieństwa transmisji/aktywacji, - pojemności/progi na węzłach/krawędziach, - parametry dynamiki na strukturze (bez zmiany topologii).

Zalety: tanie i audytowalne (zmienia się głównie warstwa atrybutów).

Ryzyko: nie bada wprost wrażliwości na topologię (tylko na parametry na topologii).

Mapowanie warunkowe: próbkowanie → reguły generatora / rewiring

Variant: X parametryzuje proces konstrukcji topologii, np.: - preferencyjne dołączanie, - triadic closure, - model blokowy (SBM) przez parametry gęstości wewnątrz/między blokami, - reguły rewiring (np. utrzymuj rozkład stopni, ale zmieniaj klastrowanie).

To jest naturalna droga od metaprzestrzeni do „struktur z rodziny” (dystrybucji struktur).

W literaturze higher-order analogiczna idea występuje też jako „dobór rzędu modelu zależności” (np. modele ścieżkowe, n-gramowe na węzłach), gdzie parametrem jest stopień pamięci. ²⁴

Progi: próbkowanie → aktywacja krawędzi / hiperkrawędzi

Variant: generujesz latentny sygnał podobieństwa/siły $w(u, v; X)$, a następnie: - $E = \{(u, v) : w(u, v; X) \geq \tau(X)\}$, - albo top-k (utrzymujesz stałą liczbę krawędzi).

To mapowanie jest z *definicji progowe*, więc spodziewaj się silnych interakcji między parametrami „skali” i parametrami „progu” (metarelace w Sobolu). ²⁵

Transformacje funkcjonalne: kernela / embeddingi

Variant: 1) X parametryzuje embedding $\phi_X(v) \in \mathbb{R}^d$, lub kernel $k_X(u, v)$,
2) struktura wynika z embeddingu (np. progowanie odległości, kNN, kernel graph),
3) ewentualnie przejście na hipergraf: hiperkrawędź = „grupa w sąsiedztwie” w embeddingu.

W praktyce bibliografia hipergrafów dostarcza formalnych narzędzi klastrowania i embeddingu specyficznie dla relacji grupowych (a nie tylko dla grafów dyadycznych). ²⁶

Agregacje motywów: motywy → hiperkrawędzie / „motif adjacency”

Variant: - najpierw wykrywasz motywy (np. trójkąty, feed-forward loops w grafach skierowanych), - potem motyw zamieniasz na relację wyższego rzędu: - hiperkrawędzie = instancje motywu, - albo konstruujesz „motif adjacency” i wykonujesz klastrowanie na tej macierzy.

To podejście jest wprost motywowane pracą o higher-order organization, gdzie analiza opiera się na subgrafach jako obiektach „wyższego rzędu”. ²⁷

Reprezentacje probabilistyczne: graphon jako mapa metaprzestrzeni do rozkładów grafów

Variant: - metaprzestrzeń parametryzuje kernel $W_X : [0, 1]^2 \rightarrow [0, 1]$, - losujesz n punktów $u_i \sim U[0, 1]$, - krawędzie są niezależne: $A_{ij} \sim \text{Bernoulli}(W_X(u_i, u_j))$.

To jest formalnie elegancki sposób mapowania „parametry → (dystrybucja struktur)”, szczególnie gdy struktury są gęste i interesuje Cię teoria granic i sampling. ²⁸

Tabela porównawcza metod mapowania

Metoda mapowania	Opis	Koszt (rzędu na próbkę)	Zalety	Wady / ryzyka	Kiedy użyć
Atrybuty na stałej topologii	X steruje wagami/ progami bez zmiany E	$O(E)$	stabilne, tanie, łatwe do audytu	nie bada zmian topologii	gdy chcesz „czyste” indeksy dla parametrów dynamiki/ atrybutów
Generator / rewiring	X parametryzuje tworzenie G	$O(E)$ - $O(V ^2)$	bada wrażliwość na topologię	stochastyczność generatora, potrzeba replik	gdy topologia jest elementem niepewności
Kernel + progowanie	$X \Rightarrow k_X \Rightarrow E(\tau)$	często $O(V ^2)$	naturalne dla podobieństw/ embeddingów	silna wrażliwość na próg; „phase changes”	gdy relacje są „z podobieństwa”
Motywy $\rightarrow$ hipergraf	instancje motywów jako relacje grupowe	zależne od motywu (bywa wysokie)	odkrywa organizację wyższego rzędu	koszt liczenia motywów; wybór motywu zmienia wynik	gdy „funkcja” siedzi w małych subgrafach
Clique complex / simplicial closure	graf $\rightarrow$ kliki $\rightarrow$ sympleksy	może eksplodować	spójne graf $\rightarrow$ simplicial	eksplozja kliki, potrzeba cutoff	gdy modelujesz grupowe interakcje „z klik”
Graphon	$X \Rightarrow W_X \Rightarrow$ losowanie grafu	$O(V ^2)$	formalny model probabilistyczny + sampling	głównie dla gęstych grafów; identyfikacja bywa trudna	gdy chcesz modelować rozkład struktur, nie pojedynczą strukturę

Uwaga metodyczna: jeśli rozważasz hipergrafy i kompleksy symplecjialne „zamiennie”, literatura pokazuje, że to może zmieniać wnioski o dynamice (nie jest równoważne). ²⁹

Sobol/ANOVA jako detektor metarelacji w metaprzestrzeni

Indeksy Sobola i ich sens w tym problemie

Niech $Y = f(X)$ (tu: metryka strukturalna albo metryka dynamiki na strukturze). Sobol pokazuje, że można rozłożyć wariancję Y na wkłady efektów pojedynczych i interakcji (ANOVA-reprezentacja na hipersześcianie), a indeksy Sobola są znormalizowanymi udziałami tych wkładów. ²²

W praktyce obliczeniowej (Saltelli/pick-freeze/Jansen) buduje się macierze próbek A, B i macierze hybrydowe $A_B^{(i)}$, aby estymować: - S_i — efekt pierwszego rzędu (main effect), - S_{ij} — interakcja pary, - S_{T_i} — efekt całkowity (main + wszystkie interakcje z innymi). ¹⁰

Warunek kluczowy: klasyczne formuły zakładają wejścia niezależne / nie skorelowane; Saltelli omawia ten warunek wprost (input factors uncorrelated) i rozdziela przypadki zależności. ³⁰

Metarelacje jako „wkład interakcyjny”: dlaczego $S_{T_i} - S_i$ jest wskaźnikiem modulacji

W Twoim języku „metarelacja” to czynnik, który **nie tyle bezpośrednio zmienia strukturę**, co zmienia *to, jak inne czynniki zmieniają strukturę*. W formalizmie Sobola jest to dokładnie „wkład w interakcjach”.

Praktyczna miara robocza:

$$K_i := S_{T_i} - S_i$$

Interpretacja: - $K_i \approx 0$: czynnik działa głównie addytywnie (bez silnej modulacji), - duże K_i : czynnik działa głównie przez interakcje $\rightarrow$ „modulator mapowania/struktury”. ¹

W mapowaniach progowych i kernelowych jest to niemal reguła: „skala” i „próg” zwykle silnie współdziałają, bo jeden parametr bez drugiego nie determinuje topologii; to powinno dawać podniesione S_{ij} i K_i . ³¹

Sobol w metaprzestrzeni „wyższych rzędów”

Jeśli $g(X)$ generuje nie tylko graf, ale hipergraf/kompleks sympleksyjny lub model zależności ścieżkowych, możesz liczyć Sobola na: - metrykach strukturalnych (np. „higher-order clustering”, liczby sympleksów), - metrykach dynamik (np. próg epidemii, synchronizacja, czas do przejścia fazowego).

Wyniki o tym, że wyższy rząd może generować nowe zjawiska (np. przejścia nieciągłe) uzasadniają, że metaprzestrzeń powinna obejmować parametry „wyższego rzędu”, a Sobol ma szansę pokazać „kto moduluje próg”. ³²

Projekt eksperymentu Monte Carlo i quasi-Monte Carlo do testowania mapowań

Cele i pytania badawcze

Cel główny: porównać rodziny mapowań g (metaprzestrzeń $\rightarrow$ struktura) pod kątem:

(1) sterowalności metryk strukturalnych; (2) stabilności wniosków Sobola (rankingi S_i , interakcje S_{ij} , miary K_i); (3) kosztu obliczeniowego; (4) odtwarzalności w reżimie absolutnym. ³³

Pytania badawcze (operacyjne): - Jakie wymiary metaprzestrzeni sterują daną metryką strukturalną w danym mapowaniu? ²²

- Które mapowania generują najsilniejsze metarelacje (duże K_i i/lub wysokie S_{ij})? ³⁰

- Czy QMC (sekwencje Sobola) stabilizuje wnioski szybciej niż MC dla tego samego budżetu? (kwestia pokrycia hipersześcianu). ³⁴

- Jak zmieniają się wnioski, gdy „wyższy rząd” reprezentujesz jako hipergraf vs kompleks symplecjalny?

35

Przestrzeń parametrów i rozkłady wejść

Nieokreślone → proponowana struktura SPEC:

- `param_names`: lista D parametrów, np. $[p_{edge}, \tau, \sigma_k, q_{coupling}, \beta_2, \dots]$,
- `distributions`: jawne F_i (wraz z uzasadnieniem),
- `mapping_family`: identyfikator mapowania (np. `ATTR_FIXED_TOPO`, `KERNEL_THRESH`, `MOTIF_HYPER`, `GRAPHON`),
- `structure_type`: `graph|hypergraph|simplicial|multilayer|path_model`,
- `metrics`: lista metryk $Y_1, \dots, Y_K$.

Minimalne warianty rozkładów (do testów odporności na założenia): - uniform w widełkach: baseline, - beta dla parametrów w (0,1) (progi, udziały), - lognormal/gamma dla dodatnich skal. 6

Liczba prób i schematy próbkowania

Nieokreślone → propozycje wariantów N (przy D wymiarach): - $N = 1024$: debug + sanity checks, - $N = 4096$: pierwsza stabilizacja rankingów, - $N = 16384$: tryb publikacyjny / mocniejsze CI.

Schematy: - **MC**: prosty baseline, - **QMC (sekwencje Sobola)**: lepsze pokrycie hipersześcianu; historycznie powiązane z pracą Sobola o rozkładzie punktów w sześcianie. 36

- **RQMC (scrambling)**: umożliwia estymację wariancji/niepewności przy zachowaniu zalet QMC; Owen analizuje wariancję dla scrambled nets/sequences. 37

- **Saltelli/Jansen**: projekt do estymacji S_1 i S_T (oraz opcjonalnie S_2); Jansen wskazuje, że design ANOVA można łączyć z różnymi samplingami, w tym scrambled quasi-random. 10

- **Morris**: screening przy dużym D (redukcja wymiaru przed Sobolem). 38

Metryki strukturalne i procedury walidacji

Minimalny, sensowny zestaw metryk (dobierz do typu struktury): - spójność: rozmiar LCC, liczba składowych, gęstość, - modularność / community: modularność lub metryki pokrewne, - motywy: liczniki wybranych subgrafów (jeśli to jest rdzeń mapowania), - spektralne: luka spektralna Laplasjanu (proxy mieszania/spójności), - wyższy rząd: liczby hiperkrawędzi k -rzędu; liczby sympleksów; miary „higher-order” z literatury, - dla path-models: metryki pamięci/porządków (np. poprawa dopasowania względem modelu 1-rzędu). 39

Walidacja (warstwa metodologiczna): - testy kontrolne: uruchomienie Sobola na benchmarkach (funkcje testowe) przed badaniem właściwym, 40

- stabilność indeksów: porównanie wyników dla rosnących N (oraz dla różnych wariantów rozkładów), 30

- analiza wrażliwości na reprezentację higher-order (hipergraf vs symplecjalny): porównanie rankingów i interakcji, bo literatura pokazuje, że reprezentacja może zmieniać wnioski o dynamice. 41

Tabela porównawcza schematów próbkowania

Schemat	Co testuje	Koszt ewaluacji modelu	Zalety	Ograniczenia / ryzyka	Źródła metodyczne
MC	baseline rozkładów i metryk	$\sim N$	proste, standardowe CI	wolniejsza stabilizacja w wysokim D	22
QMC (Sobol seq.)	lepsze pokrycie $[0, 1]^D$	$\sim N$	niska dyskrepancja, często szybsza zbieżność całek	bez randomizacji trudniej o błąd jak w MC	36
RQMC (scrambling)	QMC + estymacja wariancji	$\sim k \cdot N$	zalety QMC + wariancja/CI	dodatkowy parametr k , rygor seedów	37
Saltelli/Jansen	S_1, S_T + metarelacje	$\sim (D + 2)N$	standard w GSA, interpretowalne interakcje	wymaga jawnych rozkładów i (klasycznie) niezależnych wejść	10
Morris	screening (redukcja D)	$\sim r(D + 1)$	tani screening	nie daje pełnej dekompozycji wariancji	38

Mermaid: pipeline eksperymentu

flowchart TD

```

A[SPEC: X, rozkłady, typ struktury, rodzina mapowania g, metryki m, seed-policy] --> B[Sampling: MC / QMC (Sobol) / RQMC / Saltelli-Jansen / Morris]
B --> C[Transformacja  $U[0,1]^D \rightarrow X$  (inverse-CDF / mapowanie marginali)]
C --> D[Mapowanie:  $g(X) \rightarrow$  struktura S (graph / hypergraph / simplicial / multilayer / path-model)]
D --> E[Metryki:  $m(S) \rightarrow Y1..YK$  (spójność, modularność, motywy, spektralne, higher-order)]
E --> F[Estymacja Sobola:  $S_1, S_T$ , (wybrane  $S_2$ );  $K_i = S_T - S_1$ ]
F --> G[Walidacja: benchmarki, stabilność vs N, bootstrap/CI, porównanie reprezentacji]
G --> H[Artefakty: wyniki, manifest runów, hashe, raport, środowisko (Docker/lockfile)]

```

Algorytmy i pseudokod

Pseudokod (Python) pokazuje klucz: **oddziel generację próbek w $[0, 1]^D$ od mapowania do rozkładów i od mapowania do struktury.**


```

# SPEC (nieokreślone -> do uzupełnienia):
# - D, param_names
# - distributions: lista obiektów z ppf ( $F^{-1}$ )
# - mapping family g(mapping_id, x, rng/seed) -> structure
# - metrics m(structure) -> dict[str, float]
# - outputs: lista metryk, które analizujesz Sobolem

def sample_U(method, N, D, seed):
    if method == "MC":
        rng = np.random.default_rng(seed)
        return rng.random((N, D))
    if method == "QMC_SOBOL":
        sob = scipy.stats.qmc.Sobol(d=D, scramble=False, seed=seed)
        return sob.random(N)
    if method == "RQMC_SOBOL":
        sob = scipy.stats.qmc.Sobol(d=D, scramble=True, seed=seed)
        return sob.random(N)

def U_to_X(U, distributions):
    X = np.zeros_like(U)
    for i, dist in enumerate(distributions):
        X[:, i] = dist.ppf(U[:, i]) #  $x_i = F_i^{-1}(u_i)$ 
    return X

def run_one(mapping_id, x, seed):
    rng = np.random.default_rng(seed)
    S = g(mapping_id, x, rng=rng) # struktura
    y = m(S) # metryki
    return y

# Design Saltelli/Jansen: param_values zawiera A,B i hybrydy
param_values = saltelli.sample(problem, N, calc_second_order=False)
Y = np.array([run_one(mapping_id, x, seed=seed_k)["metric_name"]
               for seed_k, x in enumerate(param_values)])

Si = sobol.analyze(problem, Y, calc_second_order=False)
S1 = Si["S1"]; ST = Si["ST"]
K = ST - S1

```

Implementacja w praktyce: - Python: SALib (Sobol + Morris) jako standardowy wybór biblioteczny. ⁴²

- R: `sensitivity` / inne pakiety Sobol-owe (Jansen, Saltelli) — spójne z literaturą Jansen/Saltelli. ⁴³

Koszt obliczeniowy: - $S_1 + S_T$ w schemacie Saltelli/Jansen: $\sim (D + 2)N$ ewaluacji modelu; przy rosnącym D koszt rośnie liniowo. ¹⁰

- RQMC: jeśli robisz k niezależnych scramble-runów, koszt $\sim kN$, ale zyskujesz estymację wariancji/CI w duchu MC. ³⁷

Reżim naukowy absolutny, ograniczenia i ryzyka

Minimalne wymagania rygoru

„Reżim absolutny” traktuję jako kontrakt, którego cel jest zgodny z definicjami: - **reproducibility** (odtworzenie obliczeń na tych samych danych i kodzie), - **replicability** (zgodność wniosków w niezależnym badaniu). ⁴⁴

Do tego dochodzi rama „artefakty jako obiekty badawcze” — FAIR (Findable, Accessible, Interoperable, Reusable). ⁴⁵

Artefakty wymagane w repo

Proponowany zestaw plików (gotowy do wpięcia do repo; nazwy możesz zachować):

- `SPEC.yaml`
- parametry X , rozkłady, typ struktury, rodziny mapowań, metryki, warianty N , polityka seedów.
- `SEED_POLICY.md`
- master-seed, seedy potomne (sampling vs generator struktur vs bootstrap), jednoznaczne reguły derivacji.
- `RUN_MANIFEST.jsonl` (1 linia = 1 run)
- commit SHA, data, mapping_id, sampling_id, N, D, seed, hash wyników, czas.
- `environment/`
- `Dockerfile` + lockfile (Poetry/Conda) lub `renv.lock` w R.
- `results/raw/` + `results/derived/`
- surowe metryki (próbka → metryki), indeksy Sobola, CI/bootstrap.
- `reports/`
- raport porównawczy mapowań + wykresy stabilności.
- `tests/`
- benchmarki (funkcje testowe GSA), sanity checks metryk i mapowań.

Repozytoria, które przeszukałeś, już zawierają wzorce „artefaktyzacji procesu” jako graf i metryki (glitchlab) — to jest bardzo dobre „rusztowanie” do absolutnego reżimu: pipeline jest materializowany jako DAG z metrykami in/out, a dodatkowo policzone są globalne metryki grafowe i zapisane jako artefakt JSON. ² ³

Analogicznie, w `sbom` masz „mapowanie artefaktu na graf zależności” oraz logikę „analiza delt i progi sterowania”, co jest bezpośrednio kompatybilne z myśleniem o mapowaniach progowych w metaprzestrzeni. ⁴

Ryzyka i ograniczenia

Najważniejsze ograniczenia metodologiczne: - **Zależności wejść**: klasyczny Sobol/Saltelli zakłada niezależność/nie-skorelowanie; korelacje wymagają osobnego traktowania albo redefinicji problemu.

- ⁶
- „**Perfunctory SA**”: analiza OAT (one-at-a-time) jest metodycznie zwodnicza w wysokim wymiarze; istnieje formalna krytyka i argumenty geometryczne przeciw OAT. ³⁸
- **Niestabilność indeksów przy małym N** : silne nieliniowości, progi i przejścia fazowe powodują duże błędy estymacji; QMC/RQMC może pomóc, ale nie zastępuje diagnostyki stabilności. ³⁴
- **Koszt metryk wyższego rzędu**: liczenie motywów/klik może eksplodować; potrzebujesz cutoffów i

jawnego budżetu. ⁴⁶

- **Ryzyko reprezentacyjne**: hipergraf vs kompleks symplecjalny może dawać inny wniosek o dynamice; to trzeba traktować jako zmienną eksperymentalną, a nie detal implementacyjny. ⁴¹

Etyka i dual-use

Mapowanie metaprzestrzeni do struktur i analiza wrażliwości mogą służyć zarówno do poprawy odporności systemów, jak i do optymalizacji oddziaływań na struktury (dual-use). „Reżim absolutny” powinien więc obejmować również: - ograniczenie pracy do danych syntetycznych lub uprawnionych, - minimalizację publikowania detali, które mapują się bezpośrednio na operacyjne systemy krytyczne, - jawny opis zakresu i ograniczeń, aby uniknąć nadinterpretacji wyników. ⁴⁷

Mermaid: timeline wdrożenia w repo

```
timeline
    title Harmonogram wdrożenia eksperymentu (reżim absolutny)
    SPEC : domknięcie X, rozkładów, metryk, mapowań, seed-policy
    Implementacja : moduły g() i m(); testy deterministyczności; benchmarki GSA
    Screening : Morris (opcjonalnie) i redukcja D; wybór kluczowych S2-par
    Produkcja : Saltelli/Jansen + MC/QMC/RQMC; logowanie run-manifest
    Analiza : S1, ST, K_i, S2; stabilność vs N; porównanie rodzin mapowań
    Pakietowanie : artefakty FAIR + Docker/lockfiles + checksumy
    Audyt : re-run na czysto; porównanie wyników; raport rozbieżności
```

Kluczowe referencje

- Sobol — indeksy globalnej wrażliwości, ANOVA-reprezentacja na hipersześcianie. ²²
- Saltelli — efektywne estymatory S_1 i S_T , założenie o nie-skorelowanych wejściach. ³⁰
- Jansen — projekty ANOVA dla wyjść modelu; możliwość łączenia designu z różnymi samplingami (w tym scrambled quasi-random). ⁴⁸
- Sobol (1967) — rozkład punktów w sześcianie (fundament QMC/sekwencji Sobola). ⁴⁹
- Owen — wariancja całkowania dla scrambled nets/sequences (podstawa RQMC i CI). ³⁷
- Higher-order networks (przegląd) — uzasadnienie struktur poza dyadami. ⁵⁰
- Simplicial contagion — przykład, że wyższy rząd zmienia naturę przejść (nieciągłość, bistabilność). ⁵¹
- Hipergrafy: uczenie/embedding/spectral clustering. ²⁶
- Motywy: higher-order organization i klastrowanie na podstawie subgrafów. ²⁷
- Higher-order models zależności ścieżkowych (Nature Physics Perspective). ²⁴
- Graphony i teoria granic grafów. ²⁸
- Anty-OAT („perfunctory SA”). ³⁸
- Narzędzia: SALib (Python) jako praktyczna implementacja Sobol/Morris. ⁴²
- Reproducibility vs replicability (definicje) i FAIR. ⁴⁷

¹ ⁵ ⁹ ²² ²⁵ ³³ ⁴⁰ https://www.andreasaltelli.eu/file/repository/Sobol_2001.pdf
https://www.andreasaltelli.eu/file/repository/Sobol_2001.pdf

² [graph.py](https://github.com/DonkeyJLove/glitchlab/blob/e19a649940ba4b1bea50b10e69622ba8d05a5a61/core/graph.py)
<https://github.com/DonkeyJLove/glitchlab/blob/e19a649940ba4b1bea50b10e69622ba8d05a5a61/core/graph.py>

- 3 **graph_metrics.py**
https://github.com/DonkeyJLove/glitchlab/blob/e19a649940ba4b1bea50b10e69622ba8d05a5a61/analysis/graph_metrics.py
- 4 **kryptologia-informacyjna-sbom.md**
<https://github.com/DonkeyJLove/sbom/blob/77fbb61e4d583ff4f91cce8c06cdc61e31201c96/kryptologia-informacyjna-sbom.md>
- 6 10 30 **https://www.andreasaltelli.eu/file/repository/Making_best_use.pdf**
https://www.andreasaltelli.eu/file/repository/Making_best_use.pdf
- 7 39 50 **<https://www.sciencedirect.com/science/article/pii/S0370157320302489>**
<https://www.sciencedirect.com/science/article/pii/S0370157320302489>
- 8 44 47 **<https://nap.nationalacademies.org/read/25303/chapter/2>**
<https://nap.nationalacademies.org/read/25303/chapter/2>
- 11 31 38 **<https://hero.epa.gov/reference/1060594/>**
<https://hero.epa.gov/reference/1060594/>
- 12 **badania/MQL5Market/szkiolet_badawczy.py**
https://github.com/DonkeyJLove/writeups/blob/6205f3f37844f64553ce799d82a8a52b5e489321/badania/MQL5Market/szkiolet_badawczy.py
- 13 **doc/księgamozai9d.md**
<https://github.com/DonkeyJLove/chunk-chunk/blob/b71a1d69b912f3cb9d793ef433573fb7e77ae6e8/doc/ksi%C4%99gamozai9d.md>
- 14 **hmk9d_protocol.yaml**
https://github.com/DonkeyJLove/chunk-chunk/blob/b71a1d69b912f3cb9d793ef433573fb7e77ae6e8/hmk9d_protocol.yaml
- 15 **security/README.md**
<https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/security/README.md>
- 16 **security/policies/README.md**
<https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/security/policies/README.md>
- 17 **LAT_GLX_PROJECT_MOSAIC.MD**
https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/LAT_GLX_PROJECT_MOSAIC.MD
- 18 **platform.md**
https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/platform.md
- 19 **HUD_spec.md**
https://github.com/DonkeyJLove/HA2D/blob/8b22ee8de388af3b9cf26365e1679cc6c356ef2a/HUD_spec.md
- 20 **analysis/project_graph.py**
https://github.com/DonkeyJLove/glitchlab/blob/e19a649940ba4b1bea50b10e69622ba8d05a5a61/analysis/project_graph.py
- 21 42 **<https://joss.theoj.org/papers/10.21105/joss.00097>**
<https://joss.theoj.org/papers/10.21105/joss.00097>
- 23 29 35 41 **<https://www.nature.com/articles/s41467-023-37190-9>**
<https://www.nature.com/articles/s41467-023-37190-9>
- 24 **<https://www.nature.com/articles/s41567-019-0459-y>**
<https://www.nature.com/articles/s41567-019-0459-y>
- 26 **<https://papers.nips.cc/paper/3128-learning-with-hypergraphs-clustering-classification-and-embedding>**
<https://papers.nips.cc/paper/3128-learning-with-hypergraphs-clustering-classification-and-embedding>

- 27 46 <https://pubmed.ncbi.nlm.nih.gov/27387949/>
<https://pubmed.ncbi.nlm.nih.gov/27387949/>
- 28 <https://www.ams.org/books/coll/060/>
<https://www.ams.org/books/coll/060/>
- 32 51 <https://www.nature.com/articles/s41467-019-10431-6>
<https://www.nature.com/articles/s41467-019-10431-6>
- 34 36 49 <https://www.mathnet.ru/eng/zvmmf7334>
<https://www.mathnet.ru/eng/zvmmf7334>
- 37 <https://www.sciencedirect.com/science/article/abs/pii/S0167715299000188>
<https://www.sciencedirect.com/science/article/abs/pii/S0167715299000188>
- 43 48 <https://research.wur.nl/en/publications/analysis-of-variance-for-model-output/>
<https://research.wur.nl/en/publications/analysis-of-variance-for-model-output/>
- 45 <https://www.nature.com/articles/sdata201618>
<https://www.nature.com/articles/sdata201618>